UNIVERSIDADE DE FORTALEZA · DOUTORADO

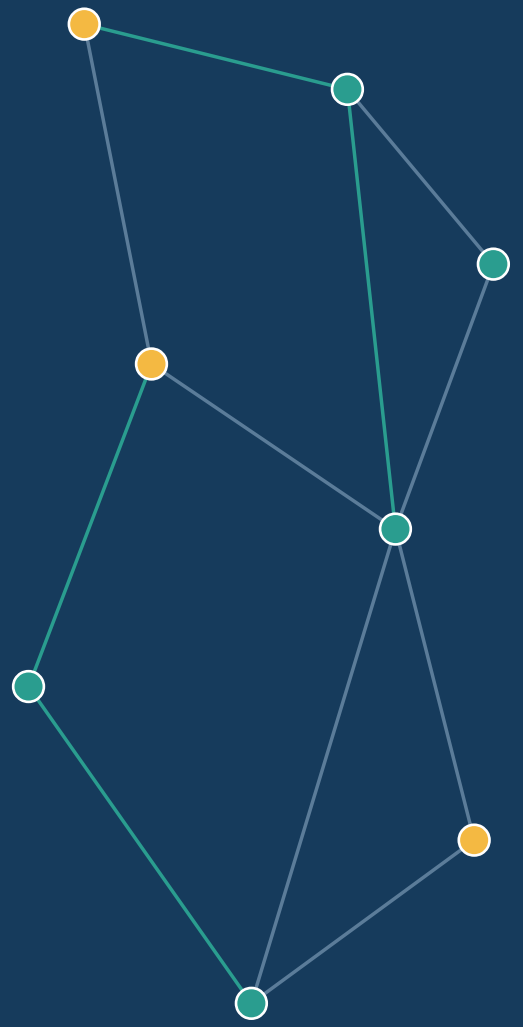
PLN em nuvem: contexto, ironia e regionalismos

Comparação entre Google Cloud Natural Language e Microsoft Azure AI Language na classificação de sentimentos em português brasileiro

João David de Freitas Cesário · Sérgio Maia Raulino · Ana Paula Silva de Araujo

Ambientes em Nuvem para Ciência de Dados e Inteligência Artificial

90 FRASES · 2 SERVIÇOS · 2 CENÁRIOS



O sentimento nem sempre está nas palavras

O problema é distinguir a polaridade literal do sentimento pretendido na situação comunicativa.

PERGUNTA DE PESQUISA

O contexto muda a classificação?

Comparar duas APIs em frases com ironia, sarcasmo e regionalismos.

2 APIs × 2 cenários

OBJETIVO GERAL

Avaliar e comparar a acurácia de Google Cloud Natural Language e Azure AI Language.

O QUE VARIA NO EXPERIMENTO?

- Serviço: Google Cloud ou Microsoft Azure
- Entrada: texto com contexto ou fala isolada
- Resultado: rótulo previsto comparado ao gabarito

O conjunto contém 90 frases de um dataset especializado

Fonte indicada no código: ramondomiingos/ptbr-irony-idioms-regionalism, carregado via Hugging Face.

PERFIL DO CONJUNTO

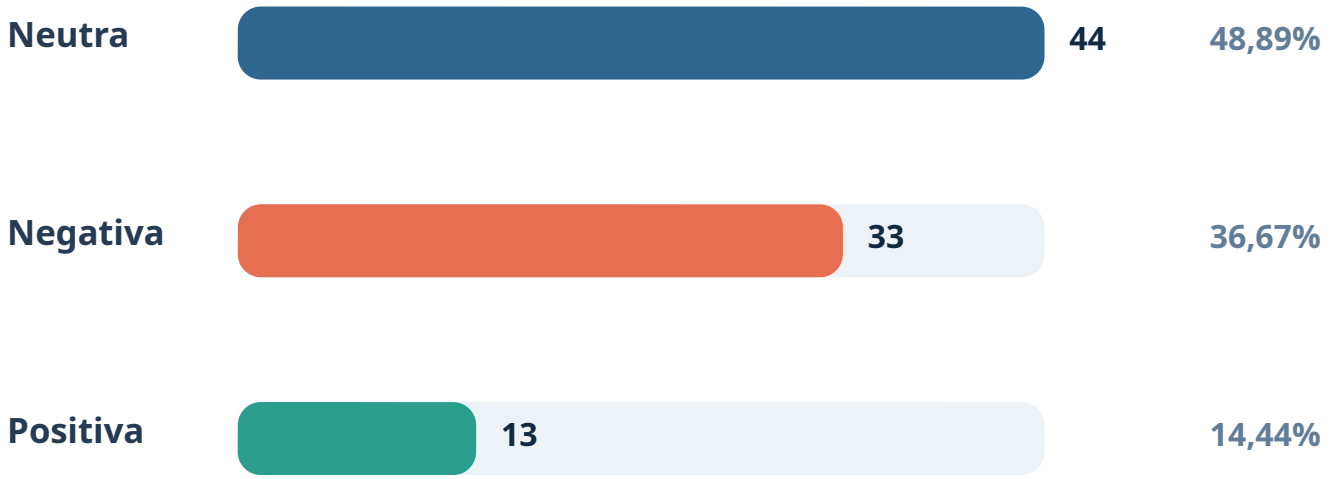
90

frases no split train

- Uma única fonte de dados.
- Três classes após o mapeamento.
- Frases desafiadoras, não amostra aleatória da língua.

ESTUDO EXPLORATÓRIO

DISTRIBUIÇÃO DO GABARITO



A classe positiva tem apenas 13 exemplos; erros individuais afetam bastante as métricas por classe.

A ablação compara a entrada completa com a fala isolada

O cenário sem contexto foi criado pela extração da primeira expressão entre aspas via Regex.

COM CONTEXTO

[Cliente irritado com o atraso] “Parabéns pela velocidade!”

A descrição da situação pode inverter a leitura literal da frase.

Entrada enviada à API

Texto de Entrada completo

Mais informação disponível

SEM CONTEXTO

“Parabéns pela velocidade!”

A fala é analisada sem a explicação sobre o atraso.

Entrada enviada à API

Frase_Isolada (Regex)

Possível perda de pistas

Do dataset às matrizes de confusão

O mesmo conjunto foi submetido às duas APIs em duas condições de entrada.

01

1. Carregar

Hugging Face
→ pandas

02

2. Preparar

Texto completo
+ frase isolada

03

3. Consultar

Azure e GCP
2 cenários

04

4. Avaliar

Gabarito × rótulo
acurácia / matrizes

VOLUME DE CONSULTAS

Até 180 requisições por serviço

90 entradas com contexto + 90 entradas sem contexto, em chamadas individuais.

CONTROLE DA COMPARAÇÃO

Mesmo conjunto; APIs diferentes

A comparação exige documentar como scores e categorias viraram as três classes finais.

Azure AI Language: recurso em Brazil South

No trabalho, o acesso foi feito com a cota/benefício de estudante; o recurso de linguagem foi configurado no plano Free F0.

CONFIGURAÇÃO USADA

Azure AI Language

Brazil South

Região do recurso

Free F0 + benefício estudantil

O benefício/cota de conta e o tier do recurso são informações distintas.

COMO O CÓDIGO CHAMA A API

TRECHO REPRESENTATIVO — CREDENCIAIS OMITIDAS

```
azure_client = TextAnalyticsClient(
    endpoint=endpoint,
    credential=AzureKeyCredential(key)
)

result = azure_client.analyze_sentiment([
    {"id": "1", "language": "pt", "text": texto[:5000]}
])[0]
sentimento = result.sentiment
```

- Entrada: texto com limite de 5.000 caracteres no código.
- Saída: positive, neutral, negative ou mixed.
- Chamadas realizadas por linha com pandas .apply().

Cloud Natural Language: score numérico de sentimento

O GCP foi acessado por Service Account, sem uso da cota/benefício de estudante informado para o Azure.

COMO O CÓDIGO CHAMA A API

TRECHO REPRESENTATIVO — CAMINHO ILUSTRATIVO

```
os.environ["GOOGLE_APPLICATION_CREDENTIALS"] =
    "/content/<service-account>.json"
client = language_v2.LanguageServiceClient()

doc = language_v2.Document(
    content=str(texto), type_=PLAIN_TEXT,
    language_code="pt"
)
res = client.analyze_sentiment(request={"document": doc})
score = res.document_sentiment.score
magnitude = res.document_sentiment.magnitude
```

- Autenticação por arquivo JSON de Service Account.
- Saída inclui score (−1 a +1) e magnitude.
- Duas análises por frase: completa e isolada.

DIFERENÇA-CHAVE

Azure

Entrega rótulo categórico

Google Cloud

Entrega score contínuo + magnitude

Implicação

Para comparar, foi preciso converter o score em classe.

Como o texto foi carregado e o contexto foi removido

A preparação foi executada em Python no Google Colab, mantendo as 90 linhas do split train.

TRECHO SIMPLIFICADO DO CÓDIGO ORIGINAL

```
from datasets import load_dataset
import pandas as pd
import re

dataset = load_dataset(
  "ramondomiingos/ptbr-irony-idioms-regionalism",
  split="train"
)
df = dataset.to_pandas()

def extrair_frase(texto):
    match = re.search(r"['\"](.*?)['\"]", str(texto))
    if match:
        return match.group(1)
    return texto
```

O QUE O CÓDIGO FAZ

- Carrega o conjunto e converte para DataFrame.
- Extrai o trecho entre aspas para o cenário sem contexto.

LIMITAÇÃO DA EXTRAÇÃO

A Regex captura o primeiro trecho entre aspas. Se houver aspas internas, múltiplos trechos ou ausência de aspas, a entrada pode não corresponder exatamente à fala pretendida.

O processamento foi feito por frase, nos dois cenários

Os resultados intermediários foram salvos em CSV e depois combinados para avaliação.

AZURE · RÓTULO

LÓGICA CENTRAL

```
def analisar_azure(texto):
    docs = [{"id":"1", "language":"pt",
             "text": str(texto)[:5000]}]
    r = azure_client.analyze_sentiment(docs)[0]
    return r.sentiment

df["Sentimento_Azure"] =
    df["Texto de Entrada"].apply(analisar_azure)
```

Salvamento

resultado_azure_completo.csv
resultado_azure_sem_contexto.csv

Um documento por requisição

GCP · SCORE E MAGNITUDE

LÓGICA CENTRAL

```
def analisar_gcp(texto):
    doc = language_v2.Document(
      content=str(texto), type_=PLAIN_TEXT,
      language_code="pt")
    r = gcp_client.analyze_sentiment(
      request={"document": doc})
    return (r.document_sentiment.score,
            r.document_sentiment.magnitude)
```

Salvamento

resultado_gcp_doutorado_completo.csv

O mesmo arquivo armazena score com e sem contexto.

As saídas foram convertidas para três classes

A etapa de normalização é central: ela influencia diretamente os acertos e erros calculados.

GABARITO

“Métricas de Sucesso”

O código procura palavras-chave em português para mapear cada linha:

- Tags negativas → negative
- Tags positivas → positive
- Demais casos → neutral

Referência operacional derivada por regras, não validação humana independente reportada.

GOOGLE CLOUD

Score → classe

REGRA APLICADA

score <= -0.25 → negative
score >= 0.25 → positive
caso contrário → neutral

Os limiares ±0,25 foram definidos no código; não é descrito ajuste em validação separada.

AZURE

mixed → neutral

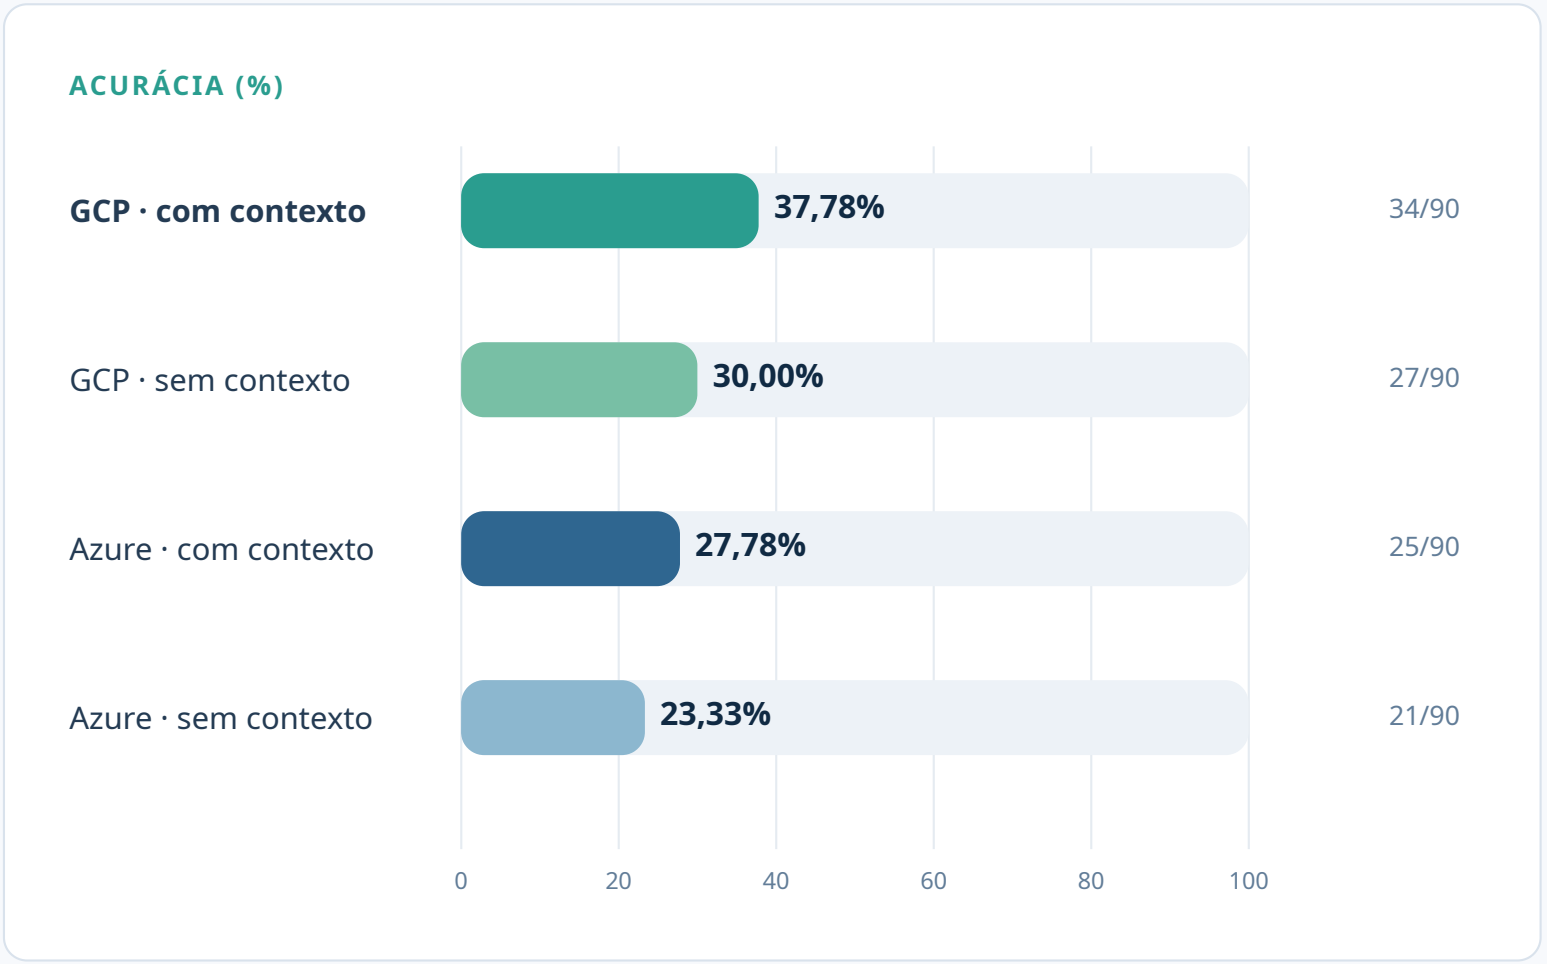
A saída categórica é padronizada em três classes; a categoria “mixed” é convertida para “neutral”.

Consequência

Regras diferentes de pós-processamento podem afetar a comparação entre provedores.

O Google Cloud teve maior acurácia nos dois cenários

Os quatro resultados usam as mesmas 90 frases e o mesmo gabarito operacional.



EFEITO OBSERVADO DO CONTEXTO

+7,78 p.p.

GCP: 30,00% → 37,78%

+4,45 p.p.

Azure: 23,33% → 27,78%

Melhor resultado: 34 acertos; 56 erros.

Diferenças descritivas; não foi reportado teste de significância estatística.

Os padrões de erro variam por serviço e cenário

Linhas = gabarito; colunas = previsão. A diagonal principal representa os acertos.

Azure · com contexto

27,78%

	Neg.	Neut.	Pos.
Neg.	**4**	10	19
Neut.	17	**15**	12
Pos.	4	3	**6**

Azure · sem contexto

23,33%

	Neg.	Neut.	Pos.
Neg.	**3**	8	22
Neut.	18	**15**	11
Pos.	5	5	**3**

GCP · com contexto

37,78%

	Neg.	Neut.	Pos.
Neg.	**5**	11	17
Neut.	14	**23**	7
Pos.	1	6	**6**

GCP · sem contexto

30,00%

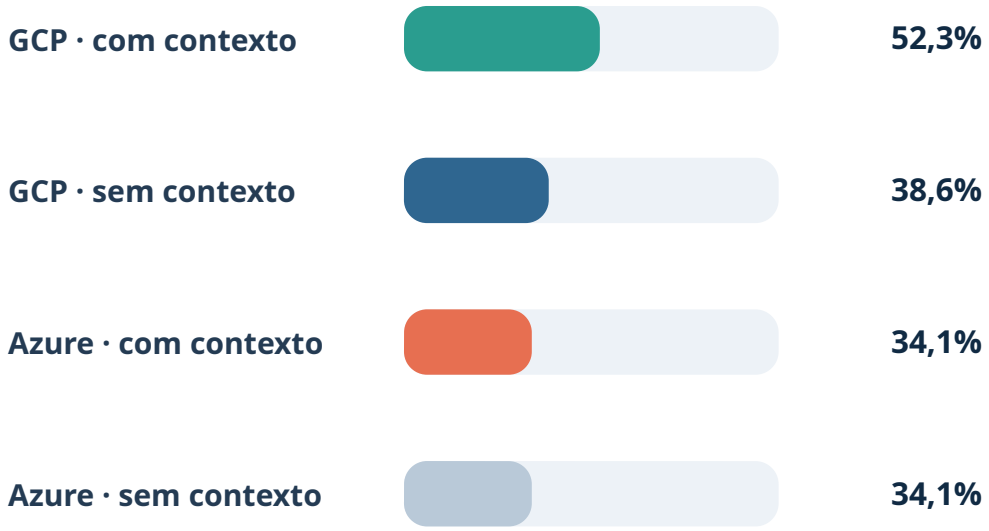
	Neg.	Neut.	Pos.
Neg.	**4**	10	19
Neut.	18	**17**	9
Pos.	1	6	**6**

ERRO RECORRENTE: gabarito negativo → previsão positiva em 17–22 frases, conforme a configuração.

A classe neutra explica parte da vantagem do GCP

A análise por classe revela diferenças que a acurácia global não mostra sozinha.

ACERTOS NA CLASSE NEUTRA



Denominador: 44 frases neutras no gabarito.

O QUE AS MATRIZES SUGEREM

- Expressões positivas podem ser classificadas literalmente mesmo em exemplos negativos.
- O contexto melhora a acurácia, mas não resolve todos os casos de ironia.
- A classe positiva tem somente 13 exemplos; estimativas por classe têm incerteza maior.

Acurácia não substitui precisão, revocação e F1 por classe.

Quatro limitações precisam acompanhar qualquer conclusão

O objetivo não é invalidar os resultados, mas delimitar exatamente o que foi medido.

01 Dados

- 90 frases; uma fonte
- Classes desbalanceadas
- Generalização limitada

02 Gabarito

- Regra por palavras-chave
- Sem validação humana independente reportada
- Possível ambiguidade

03 Conversão

- Score GCP → rótulo
- mixed → neutral no Azure
- Limiar ±0,25 heurístico

OUTRAS AMEAÇAS À VALIDADE

Contexto explícito

Pode revelar a situação e facilitar a tarefa.

Regex

Pode extrair um trecho inadequado em formatos não previstos.

Custo e latência

Não foram comparados de forma controlada.

As conclusões valem para este dataset, estas versões dos serviços e este protocolo.

Contexto ajudou, mas não eliminou os erros

Os dados sustentam uma conclusão exploratória, não uma generalização universal.

TRÊS ACHADOS

1. **Maior acurácia do GCP**
   37,78% com contexto; 30,00% sem contexto.

2. **Ganho associado ao contexto**
   +7,78 p.p. no GCP e +4,45 p.p. no Azure.

3. **Erros concentrados em padrões específicos**
   Muitas frases negativas foram previstas como positivas.

TRABALHOS FUTUROS

- Ampliar e diversificar o dataset.
- Validar rótulos com anotação humana.
- Reportar F1, precisão e revocação por classe.
- Comparar com LLMs sob o mesmo protocolo.

Mensagem final

Sentimento depende de palavras, contexto e uso pragmático.